

Quy trình Train–Valid–Test & QA/QC cho Mô hình Phân loại Tin tức (News Classification)

Tài liệu kỹ thuật — Machine Learning Pipeline

Contents


1	Tổng quan Pipeline	2
2	Quy trình Train–Valid–Test	2
2.1	Bước 1 — Thu thập & Chuẩn bị Dữ liệu	2
2.2	Bước 2 — Phân tích & Khám phá Dữ liệu (EDA)	2
2.3	Bước 3 — Chia Dữ liệu (Data Splitting)	3
2.4	Bước 4 — Tiền xử lý Văn bản (Preprocessing)	3
2.5	Bước 5 — Feature Extraction / Embedding	3
2.6	Bước 6 — Lựa chọn & Xây dựng Mô hình	3
2.7	Bước 7 — Training	4
2.8	Bước 8 — Hyperparameter Tuning (trên Validation Set)	4
2.9	Bước 9 — Đánh giá Mô hình	4
2.10	Bước 10 — Iteration & Cải tiến	5
2.11	Bước 11 — Lưu & Triển khai Mô hình	5
3	Quy trình QA/QC	5
4	Checklist QA/QC Tổng hợp	7
5	Tài liệu tham khảo	8

1 Tổng quan Pipeline

Pipeline huấn luyện mô hình phân loại tin tức bao gồm hai luồng song song:

- **Train–Valid–Test**: quy trình chuẩn xây dựng và đánh giá mô hình.
- **QA/QC**: hệ thống kiểm soát chất lượng tại từng bước, đảm bảo tính tin cậy trước khi triển khai.

Tóm tắt flow:



2 Quy trình Train–Valid–Test

2.1 Bước 1 — Thu thập & Chuẩn bị Dữ liệu

Thu thập dữ liệu

Nguồn dữ liệu:

- Scrape từ các trang tin tức: BBC, VnExpress, Reuters, Tuổi Trẻ...
- Dataset có sẵn: AG News, 20 Newsgroups, RCV1, VINEWS

Gán nhãn (Labels):

- Định nghĩa các lớp rõ ràng: *Thể thao, Chính trị, Kinh tế, Giải trí, Công nghệ...*
- Đảm bảo nhãn không mơ hồ, có hướng dẫn annotation
- Dùng annotation tool nếu cần gán nhãn thủ công (Label Studio, Prodigy)

2.2 Bước 2 — Phân tích & Khám phá Dữ liệu (EDA)

- Kiểm tra phân phối class → phát hiện **class imbalance**
- Thống kê độ dài văn bản: min/max/mean số token
- Visualize word cloud, top n-grams theo từng class
- Kiểm tra duplicate, missing values, encoding lỗi

2.3 Bước 3 — Chia Dữ liệu (Data Splitting)

Tập dữ liệu	Tỉ lệ	Mục đích
Train set	70–80%	Học tham số mô hình
Validation set	10–15%	Tuning hyperparameters
Test set	10–15%	Đánh giá cuối cùng (chỉ dùng 1 lần)

Lưu ý quan trọng

- Dùng **stratified split** để giữ phân phối class đều nhau giữa các tập
- Test set phải được **lock** ngay từ đầu — không được nhìn vào cho đến khi train xong
- Tuyệt đối tránh **data leakage**: fit tokenizer/vectorizer chỉ trên Train set

2.4 Bước 4 — Tiền xử lý Văn bản (Preprocessing)

Bước	Mô tả
Lowercase	Chuẩn hóa chữ hoa/thường
Tokenization	Tách từ/câu
Remove noise	Loại bỏ HTML, URL, ký tự đặc biệt
Stopword removal	Loại từ phổ biến không mang nghĩa
Stemming/Lemmatization	Đưa về dạng gốc của từ
Encoding	Label encoding / one-hot encoding cho nhãn

2.5 Bước 5 — Feature Extraction / Embedding

Classical ML:

- TF-IDF, Bag of Words, N-grams

Deep Learning:

- Word2Vec, GloVe, FastText
- Pretrained Transformers: **BERT**, **PhoBERT** (tiếng Việt), XLM-RoBERTa

2.6 Bước 6 — Lựa chọn & Xây dựng Mô hình

Loại	Ví dụ
Classical ML	Naive Bayes, SVM, Logistic Regression, Random Forest
Deep Learning	CNN, BiLSTM, TextCNN
Transformer	BERT fine-tune, PhoBERT, XLM-RoBERTa

2.7 Bước 7 — Training

```
for epoch in range(num_epochs):
    # Forward pass tren train set
    loss = model(X_train, y_train)

    # Backpropagation & update weights
    optimizer.step()

    # Evaluate tren validation set
    val_loss, val_acc = evaluate(X_val, y_val)

    # Early stopping neu val_loss không cải thiện
    early_stopping(val_loss)
```

Kỹ thuật hỗ trợ:

- **Early stopping** theo validation loss
- **Learning rate scheduler**: warmup, cosine decay
- **Class weights** / oversampling nếu dữ liệu mất cân bằng
- **Gradient clipping** cho Transformer

2.8 Bước 8 — Hyperparameter Tuning (trên Validation Set)

Các tham số cần điều chỉnh:

- Learning rate, batch size, số epochs
- Dropout rate, hidden size
- Max sequence length

Công cụ: Grid Search, Random Search, **Optuna**, W&B Sweeps

2.9 Bước 9 — Đánh giá Mô hình

Metric	Khi nào dùng
Accuracy	Dataset cân bằng
F1-score (macro/weighted)	Dataset mất cân bằng
Precision / Recall	Khi cost của FP và FN khác nhau
Confusion Matrix	Hiểu lỗi mô hình mắc phải

Test set — đánh giá cuối cùng

Chỉ chạy **một lần duy nhất** sau khi đã chọn xong model. Bao gồm:

- Report kết quả cuối cùng với tất cả metrics
- Phân tích error cases (những bài báo bị phân loại sai)
- So sánh với baseline và human performance

2.10 Bước 10 — Iteration & Cải tiến

Nếu kết quả chưa đạt yêu cầu, quay lại:

- Thêm dữ liệu hoặc data augmentation
- Cải thiện preprocessing
- Thử kiến trúc mô hình mạnh hơn
- Data cleaning kỹ hơn

2.11 Bước 11 — Lưu & Triển khai Mô hình

```
# Lưu model
model.save("news_classifier_v1.pt")

# Lưu tokenizer/vectorizer
pickle.dump(tokenizer, open("tokenizer.pkl", "wb"))

# Serving: FastAPI / Flask / Triton Inference Server
```

3 Quy trình QA/QC

Hệ thống QA/QC được chia thành 5 giai đoạn, mỗi giai đoạn có gate kiểm soát chất lượng riêng.

Giai đoạn 1 — QA Dữ liệu (Data Quality Assurance)

Mục tiêu: Đảm bảo dữ liệu đầu vào sạch, đầy đủ và không bị lệch.

1. **Kiểm tra nguồn & format:** xác thực schema, encoding, định dạng văn bản
2. **Dedupe & clean:** loại bỏ duplicate, null values, HTML/URL noise
3. **Class balance check:** kiểm tra phân phối nhãn, phát hiện imbalance
4. **Stratified split:** chia train/val/test có phân tầng (70/15/15)
5. **No data leakage:** lock test set ngay từ đầu, fit scaler/tokenizer chỉ trên train

Công cụ: Great Expectations, Pandas Profiling, custom validation scripts

Giai đoạn 2 — QA Nhãn (Annotation Quality Assurance)

Mục tiêu: Đảm bảo nhãn đáng tin cậy và nhất quán.

1. **Inter-Annotator Agreement (IAA):** đo độ đồng thuận giữa các annotator
 - Cohen's Kappa ≥ 0.8 là mức chấp nhận được
 - Fleiss' Kappa cho > 2 annotators

2. **Noisy label detection:** dùng Confident Learning (cleanlab) để tìm nhãn sai
 3. **Data augmentation:** synonym replacement, back-translation nếu thiếu data
- Gate Pass/Fail:** Nếu Kappa < 0.8 → quay lại **re-label**.

Giai đoạn 3 — QA Model (Training Integrity)

Mục tiêu: Kiểm soát quá trình huấn luyện, đảm bảo tính tái lập và ổn định.

1. **Reproducibility:** fix random seed, log toàn bộ hyperparameter và config
2. **Bias/Variance analysis:** theo dõi khoảng cách train loss vs val loss
 - Train loss thấp, val loss cao → overfitting
 - Cả hai đều cao → underfitting
3. **Training curves:** monitor loss, accuracy, F1 theo epoch
4. **Ablation study:** tắt từng thành phần để đo đóng góp
5. **Experiment logging:** MLflow, Weights & Biases để track mọi run

Giai đoạn 4 — QC Đánh giá (Test Set Evaluation)

Mục tiêu: Đánh giá khách quan trên test set và phát hiện lỗi hệ thống.

1. **Metrics chuẩn** (chạy trên test set, 1 lần duy nhất):

Metric	Công thức / Ghi chú
Precision	$TP / (TP + FP)$
Recall	$TP / (TP + FN)$
F1 (macro)	Trung bình không có trọng số theo class
F1 (weighted)	Trung bình có trọng số theo số mẫu
Accuracy	Phù hợp khi dataset cân bằng

2. **Error analysis:** phân tích confusion matrix, xác định class khó nhất
3. **Bias & Fairness:** kiểm tra performance theo nhóm ngôn ngữ, nguồn tin

Gate Pass/Fail: Nếu F1 < ngưỡng định sẵn → **retrain**.

Giai đoạn 5 — QC Deploy (Production Readiness)

Mục tiêu: Đảm bảo model hoạt động đúng và ổn định trong môi trường production.

1. **Regression testing:** so sánh với baseline model trước đó, không được tệ hơn
2. **Performance & Latency testing:** đo p95 latency, throughput (req/s)
3. **Shadow deployment:** chạy song song với model cũ, so sánh prediction
4. **Canary release:** rollout dần dần 5% → 20% → 100%
5. **Production monitoring:**
 - **Data drift:** PSI (Population Stability Index), KS test
 - **Concept drift:** theo dõi F1 trên production logs
 - Alert tự động khi performance giảm quá ngưỡng

Feedback loop: Khi phát hiện drift → trigger re-training pipeline từ đầu.

4 Checklist QA/QC Tổng hợp

Giai đoạn	Hạng mục kiểm tra	Trạng thái
QA Dữ liệu	Không có duplicate	
QA Dữ liệu	Không có missing values	
QA Dữ liệu	Phân phối class đã kiểm tra	
QA Dữ liệu	Test set đã lock	
QA Dữ liệu	Không có data leakage	
QA Nhân	Cohen's Kappa ≥ 0.8	
QA Nhân	Noisy label đã xử lý	
QA Nhân	Augmentation đã áp dụng (nếu cần)	
QA Model	Random seed đã fix	
QA Model	Không có overfitting rõ rệt	
QA Model	Training curves ổn định	
QA Model	Experiment đã log đầy đủ	
QC Đánh giá	F1 $\geq$ ngưỡng yêu cầu	
QC Đánh giá	Error analysis đã thực hiện	
QC Đánh giá	Bias check theo nhóm	
QC Deploy	Regression test passed	
QC Deploy	Latency p95 trong ngưỡng	
QC Deploy	Monitoring đã thiết lập	
QC Deploy	Rollback plan đã chuẩn bị	

5 Tài liệu tham khảo

1. Northcutt, C. G., Athalye, A., & Mueller, J. (2021). *Pervasive Label Errors in Test Sets Destabilize Machine Learning Benchmarks*. NeurIPS.
2. Sculley, D. et al. (2015). *Hidden Technical Debt in Machine Learning Systems*. NeurIPS.
3. Huyen, C. (2022). *Designing Machine Learning Systems*. O'Reilly Media.
4. Devlin, J. et al. (2019). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. NAACL.
5. Nguyen, D. Q. et al. (2020). *PhoBERT: Pre-trained Language Models for Vietnamese*. EMNLP Findings.